

2.2 $\text{if } R = r^{(n)}$

习题 2-1 分析为什么平方损失函数不适用于分类问题.

习题 2-2 在线性回归中, 如果我们给每个样本 $(x^{(n)}, y^{(n)})$ 赋予一个权重 $r^{(n)}$, 经 $\frac{\partial \mathcal{R}(w)}{\partial w} = -xR \cdot (y - x^T w) = 0$ 验风险函数为

$$\mathcal{R}(w) = \frac{1}{2} \sum_{n=1}^N r^{(n)} (y^{(n)} - w^T x^{(n)})^2, \quad (2.91)$$

计算其最优参数 w^* , 并分析权重 $r^{(n)}$ 的作用. 对斜率再考虑 - 一个例子

习题 2-3 证明在线性回归中, 如果样本数量 N 小于特征数量 $D + 1$, 则 XX^T 的秩最大为 N .

习题 2-4 在线性回归中, 验证岭回归的解为结构风险最小化准则下的最小二乘法估计, 见公式(2.44).

习题 2-5 在线性回归中, 若假设标签 $y \sim \mathcal{N}(w^T x, \beta)$, 并用最大似然估计来优化参数, 验证最优参数为公式(2.52)的解.

习题 2-6 假设有 N 个样本 $x^{(1)}, x^{(2)}, \dots, x^{(N)}$ 服从正态分布 $\mathcal{N}(\mu, \sigma^2)$, 其中 μ 未知. 1) 使用最大似然估计来求解最优参数 μ^{ML} ; 2) 若参数 μ 为随机变量, 并服从正态分布 $\mathcal{N}(\mu_0, \sigma_0^2)$, 使用最大后验估计来求解最优参数 μ^{MAP} .

习题 2-7 在习题 2-6 中, 证明当 $N \rightarrow \infty$ 时, 最大后验估计趋向于最大似然估计.

习题 2-8 验证公式(2.61).

习题 2-9 试分析什么因素会导致模型出现图 2.6 所示的高偏差和高方差情况.

<https://nndl.github.io/>

$$2.6 p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

$$L = \prod_{i=1}^N p(x_i) = \prod_{i=1}^N N(\mu, \sigma^2)$$

$$= \prod_{i=1}^N \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x^{(i)}-\mu)^2}{2\sigma^2}\right\}$$

$$\log L = -N \log(\sqrt{2\pi}\sigma) - \sum_{i=1}^N \frac{(x^{(i)}-\mu)^2}{2\sigma^2}$$

$$\frac{\partial \log L}{\partial \mu} = \sum_{i=1}^N \frac{1}{\sigma^2} (x^{(i)} - \mu) = 0.$$

$$\begin{aligned} \sum_{i=1}^N x^{(i)} - N\mu &= 0 \\ \mu &= \frac{1}{N} \sum_{i=1}^N x^{(i)} \\ &= \frac{X}{N} = \bar{x} \end{aligned}$$

后验 \propto 先验 \times 似然

$$2.3 \quad N < D+1$$

$$X \in \mathbb{R}^{D \times N} \quad \text{and } r(x) \in \mathbb{N}$$

$$X X^T \in \mathbb{R}^{D \times D} \quad \therefore r(X X^T) \leq r(X) \leq N$$

$$2.4 \quad \begin{aligned} \mathcal{R}(w) &= \frac{1}{2} \|y - X^T w\|^2 + \frac{\lambda}{2} \|w\|^2 \\ \frac{\partial \mathcal{R}(w)}{\partial w} &= -X(y - X^T w) + \lambda I w \\ &= -Xy + (X X^T + \lambda I) w = 0 \\ w &= (X X^T + \lambda I)^{-1} X y \end{aligned}$$

$$2.5 \quad \begin{aligned} p(y|x; \mu, \sigma^2) &= \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y - \mu)^2}{2\sigma^2}\right) \\ \log p(y|x; \mu, \sigma^2) &= \log \frac{1}{\sqrt{2\pi}\sigma} - \frac{(y - \mu)^2}{2\sigma^2} \\ \frac{\partial \log p(y|x; \mu, \sigma^2)}{\partial \mu} &= \frac{X}{\sigma^2} (y - \mu) = 0 \\ w^{ML} &= (X X^T)^{-1} X y \end{aligned}$$

$$\begin{aligned} L &\propto p(x; \mu, \sigma^2) p(\mu; \mu_0, \sigma_0^2) \\ \log L &\propto \log p(x; \mu, \sigma^2) + \log p(\mu; \mu_0, \sigma_0^2) \end{aligned}$$

$$= -\frac{1}{2\sigma^2} \sum_{i=1}^N (x^{(i)} - \mu)^2 - \frac{1}{2\sigma_0^2} (\mu - \mu_0)^2$$

$$\begin{aligned} \frac{\partial \log L}{\partial \mu} &= \frac{1}{\sigma^2} \sum_{i=1}^N (x^{(i)} - \mu) - \frac{1}{\sigma_0^2} (\mu - \mu_0) \\ &= \frac{1}{\sigma^2} \sum_{i=1}^N x^{(i)} - \frac{N\mu}{\sigma_0^2} - \frac{\mu}{\sigma_0^2} + \frac{\mu_0}{\sigma_0^2} = 0 \\ \frac{\sum_{i=1}^N x^{(i)}}{\sigma^2} + \frac{\mu_0}{\sigma_0^2} &= \left(\frac{N}{\sigma^2} + \frac{1}{\sigma_0^2}\right) \mu \end{aligned}$$

$$\mu^{MAP} = \frac{\sigma_0^2 \sum_{i=1}^N x^{(i)} + \sigma^2 \mu_0}{(N\sigma_0^2 + \sigma^2)}$$

例题正态的可得性
来源：联合概率，又 x 独立同分布，
故 $p(x)$ 为连乘的形式

$$\boxed{2.7} \quad \mu \xrightarrow{N \rightarrow \infty} \frac{\sigma_0^2 \sum_{n=1}^N x^{(n)}}{N \sigma_0^2} = \bar{x}$$

最大似然估计： $p(y|X; w, \sigma) \max$

即意味着 $p(y^{(n)}|x^{(n)}; w, \sigma) \max$

即给定 $x^{(n)}$ 下使得 $y^{(n)}$ 概率最大

最大后验估计 = 结构风险最小化 $(X^T + \lambda I)^{-1} X y$

添加正则化项相当于增加对 w 的先验约束

2.8

$$R(f) = E_{x|y, p(x|y)} [(y - f(x))^2] \text{ 联合分布}$$

$$= E_{x \sim p(x)} [E_{y \sim p(y|x)} (y - f(x))^2] \text{ 分开计算}$$

$$= E_{x \sim p(x)} [E_{y \sim p(y|x)} (y - E_{y \sim p(y|x)} y + E_{y \sim p(y|x)} y - f(x))^2] \text{ 添加常量 } E_{y \sim p(y|x)} y$$

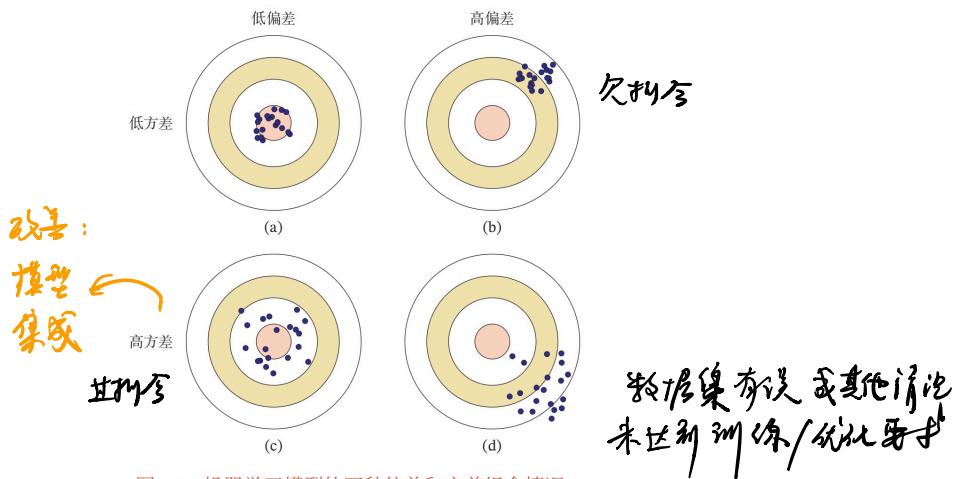
$$= E_{x \sim p(x)} [f(x) - E_y (y - E_y y)]^2 + E_y [(E_y y) - f(x)]^2 + 2 E_y [(y - E_y y)(E_y y - f(x))] \quad \text{① 与 x 无关} \quad \text{②} \quad \text{③}$$

$$\text{③ 有 } E_y [(y - E_y y)] = E_y y - E_y y = 0 \quad (E(E_{y|x}) = 0), \text{ 则 } \text{③} = 0$$

故需使 $R(f) \min$, 即 $\min - \mathbb{E}_x f(x)$, 即只有使 $f(x) = E_y y$. 即 $\text{②} = 0$

\therefore 有 $f^*(x) = E_{y \sim p(y|x)} y$ 即 $\text{②} = 0$, $R(f) \min$.

2.9



习题 2-10 验证公式(2.66).

习题 2-11 分别用一元、二元和三元特征的词袋模型表示文本“我打了张三”和“张三打了我”，并分析不同模型的优缺点.

习题 2-12 对于一个三分类问题，数据集的真实标签和模型的预测标签如下：

真实标签	1	1	2	2	2	3	3	3	3
预测标签	1	2	2	2	3	3	3	1	2

分别计算模型的精确率、召回率、F1 值以及它们的宏平均和微平均.

2.10

$$\begin{aligned}
 & E_D [(f_D(x) - f^*(x))^2] \\
 &= E_D [(f_D(x) - E_D[f_D(x)]) + E_D[f_D(x)] - f^*(x)]^2 \\
 &= \underbrace{E_D[(f_D(x) - E_D[f_D(x)])^2]}_{\text{方差}} + \underbrace{E_D[(E_D[f_D(x)] - f^*(x))^2]}_{\text{偏差}} + 2 \underbrace{E_D[(f_D(x) - E_D[f_D(x)])(f^*(x) - E_D[f_D(x)])]}_{\text{交叉项}} \\
 & \text{其中 } E_D[(f_D(x) - E_D[f_D(x)])] = 0 \quad \text{得 } \quad \left. \begin{array}{l} f^*(x) \text{ 偏差} \\ E_D[f_D(x)] \text{ 偏差} \end{array} \right\} \\
 &= E_D[(E_D[f_D(x)] - f^*(x))^2] = (E_D[f_D(x)] - f^*(x))^2 \\
 &= (\text{bias. } x)^2
 \end{aligned}$$

2.11

-元
“\$” “我” “打了” “张三” “#”

x_1 : “我打了张三”
 x_2 : “张三打了我”

$$x_1 = [1 \ 1 \ 1 \ 1 \ 1]^T$$

$$x_2 = [1 \ 1 \ 1 \ 1 \ 1]^T$$

-元之间反映顺序信息

二元

“\$我” “\$张三” “我打了” “张三打了” “打了张三” “打了我” “张三#” “我#”

$$x_1 = [1 \ 0 \ 1 \ 0 \ 1 \ 0 \ 1 \ 0]^T$$

$$x_2 = [0 \ 1 \ 0 \ 1 \ 0 \ 1 \ 0 \ 1]^T$$

三元

“\$我打了” “\$张三打了” “我打了张三” “张三打了我” “打了张三#” “打了我#”

$$x_1 = [1 \ 0 \ 1 \ 0 \ 1 \ 0]^T$$

$$x_2 = [0 \ 1 \ 0 \ 1 \ 0 \ 1]^T$$

习题 2-12 对于一个三分类问题, 数据集的真实标签和模型的预测标签如下:

	$\checkmark \checkmark \checkmark \checkmark \checkmark \checkmark$								
真实标签	1	1	2	2	2	3	3	3	3
预测标签	1	2	2	2	3	3	3	1	2
	\checkmark							\checkmark	

$$\frac{\frac{2}{3} \times 6}{7}$$

分别计算模型的精确率、召回率、F1 值以及它们的宏平均和微平均。

2.14

解题

$$CM: \begin{array}{c|c} \bar{y} = c & \bar{y} \neq c \\ \hline y=c & \begin{array}{|c|c|} \hline TP_c & TN_c \\ \hline \end{array} \\ y \neq c & \begin{array}{|c|c|} \hline FP_c & FN_c \\ \hline \end{array} \end{array}$$

$c=1$

1	1
1	6

$c=2$

2	1
2	4

$c=3$

2	2
1	4

$$c=1 \text{ 时}, P_c = \frac{1}{7}, R_c = \frac{1}{2}, F1_c = \frac{2 \times \frac{1}{7} \times \frac{1}{2}}{\frac{1}{7} + \frac{1}{2}} = \frac{1}{2}$$

$$c=2 \text{ 时}, P_c = \frac{1}{2}, R_c = \frac{2}{5}, F1_c = \frac{2 \times \frac{1}{2} \times \frac{2}{5}}{\frac{1}{2} + \frac{2}{5}} = \frac{4}{7}$$

$$c=3 \text{ 时}, P_c = \frac{2}{3}, R_c = \frac{1}{3}, F1_c = \frac{2 \times \frac{2}{3} \times \frac{1}{3}}{\frac{2}{3} + \frac{1}{3}} = \frac{4}{7}$$

$$\text{宏平均: } P_{macro} = \frac{1}{3} \times \left(\frac{1}{7} + \frac{2}{5} + \frac{2}{3} \right) = \frac{5}{9}, R_{macro} = \frac{5}{7}, F1_{macro} = \frac{2 \times \frac{5}{9} \times \frac{5}{7}}{\frac{5}{9} + \frac{5}{7}} = \frac{5}{9}$$